

**ΤΜΗΜΑ ΕΠΙΣΤΗΜΗΣ ΥΠΟΛΟΓΙΣΤΩΝ  
ΠΑΝΕΠΙΣΤΗΜΙΟ ΚΡΗΤΗΣ**



**Πτυχιακή Εργασία**

**Στατική sharing ανάλυση για βελτιστοποίηση  
δυναμικής ανίχνευσης data race**

<https://github.com/Bela-Kamilo/static-sharing-analysis-for-optimizing-dynamic-race-detection>

Κυπαρίσσης Αλέξανδρος CSD 4210

Επόπτης καθηγητής: Πολύβιος Πρατικάκης

...

Ηράκλειο Κρήτης 2025

# ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

1. Περίληψη	2
2. Εισαγωγή	
2.1 data race	
2.2 points-to ανάλυση	
3. Σχετική Δουλειά	
4. Αναλυτική περιγραφή	
4.1 Jimple IR	
4.2 Αφαίρεση θέσεων μνήμης	
4.3 Points-to Sets	
4.4 May	
4.5 Ασφαλής αφαίρεση προγράμματος	
4.6 Intra-procedural	
4.7 Πρόβλημα ικανοποίησης περιορισμών	
4.8 Κανόνες Παραγωγής	
4.8.1 Points-to	
4.8.2 Παρενέργειες	
4.9 DaCapo Benchmarks	
5. Επίλογος	
6. Αναφορές	

# 1. Περίληψη

Δυναμικές, on-the-fly, αναλύσεις προγραμμάτων παρέχουν σημαντικά περισσότερη πληροφορία από ο,τι στατικές προσεγγίσεις με σημαντικά μεγαλύτερο κόστος απόδοσης. Σκοπός αυτής της εργασίας είναι η εύρεση προσβάσεων στο heap του JVM, οι οποίες είναι αδύνατο να προκαλέσουν data race, πριν την εκτέλεση ενός προγράμματος. Βάση αυτής της πληροφορίας, μια δυναμική ανίχνευση data race μπορεί να αγνοήσει με ασφάλεια συγκεκριμένες εντολές μειώνοντας τον χρόνο εκτέλεσής της. Παρουσιάζεται μια στατική ανάλυση, ανεξάρτητη της ροής του προγράμματος, της οποίας η βάση είναι μια points-to ανάλυση.

## Abstract

Dynamic, on-the-fly, program analyses yield significantly more information than static approaches at the cost of significant performance cost. The aim of this work is finding thread safe JVM memory accesses, which are sure not to cause data races, before execution time. Using this information, a dynamic race detector can safely ignore certain instructions reducing its execution time. A static, context-insensitive, points-to based analysis is presented

## 2. Εισαγωγή

<κειμενο>

### 2.1 Data race

To specification της Java ορίζει το data race ως εξής :

<in quote format :>

When a program contains two conflicting accesses that are not ordered by a happens-before relationship, it is said to contain a *data race*.

Two accesses to (reads of or writes to) the same variable are said to be *conflicting* if at least one of the accesses is a write.<sup>1</sup>

### 2.1 Points-to ανάλυση

Η points-to ανάλυση έχει σκοπο να ανακαλύψει ποιές μεταβλητές της στοίβας του προγράμματος ενδέχεται να αναφέρονται σε ποιά objects.

Κάθε τελεστής new σηματοδοτεί την δημιουργία ενός object.

Εντολές εκχώρησης και κλήσεις μεθόδων μεταβιβάζουν τα objects μεταξύ των μεταβλητών υποδεικνύοντας σε ποιά objects ενδέχεται να αναφέρονται.

Το αποτέλεσμα είναι μία αντιστοίχιση των μεταβλητών και συνόλων από objects.

### 3. Σχετική δουλειά

<thread sanitizer>

<Andersen's analysis>

### 4. Αναλυτική περιγραφή

Η είσοδος της ανάλυσης είναι Java bytecode, η επεξεργασία του οποίου γίνεται μέσω του SootUp framework.<sup>2</sup>

Η είσοδος μετατρέπεται σε μορφή ενδιάμεσης αναπαράστασης (Jimple IR).

<entry method κάθε run() >

Εξετάζεται κάθε εντολή που εν δυνάμει εκτελείται από αυτή την μέθοδο και όποια άλλη μέθοδο καλείται αναδρομικά.

Παράγεται μια αντιστοιχία μεταβλητών και συνόλων από objects στα οποία εν δυνάμει αναφέρονται και μια αντιστοίχιση μεθόδων και προσβάσεων μνήμης.

Οι προσβάσεις μνήμης είναι της μορφής : READ/WRITE object#.field .

<read/write effect sets/set sizes>

## 4.1 Jimple IR

Η Jimple είναι η ενδιάμεση αναπαράσταση του SootUp.

- stackless
- no nested structures

παράδειγμα hello world :

```
public class HelloWorld extends java.lang.Object
{
    public void <init>()
    {
        HelloWorld r0;
        r0 := @this: HelloWorld;
        specialinvoke r0.<java.lang.Object: void <init>()>();
        return;
    }

    public static void main(java.lang.String[])
    {
        java.lang.String[] r0;
        java.io.PrintStream r1;
        r0 := @parameter0: java.lang.String[];
        r1 = <java.lang.System: java.io.PrintStream out>;
        virtualinvoke r1.<java.io.PrintStream:
        void println(java.lang.String)>("Hello world!");
        return;
    }
}
```

Αναλυτικά η γραμματική της <sup>3</sup>:

$stmt \rightarrow assignStmt \mid identityStmt \mid$ $gotoStmt \mid ifStmt \mid invokeStmt \mid$ $switchStmt \mid monitorStmt \mid$ $returnStmt \mid throwStmt \mid$ $breakpointStmt \mid nopStmt;$
$assignStmt \rightarrow local = rvalue; \mid$ $field = imm; \mid$ $local.field = imm; \mid$ $local[imm] = imm;$
$identityStmt \rightarrow local := @this: type; \mid$ $local := @parameter n: type; \mid$ $local := @exception;$
$gotoStmt \rightarrow goto label;$
$ifStmt \rightarrow if conditionExpr goto label;$
$invokeStmt \rightarrow invoke invokeExpr;$
$switchStmt \rightarrow lookupswitch imm$ $\{case value_1: goto label_1;$ $...$ $case value_n: goto label_n;$ $default: goto defaultLabel;\}; \mid$ $tableswitch imm$ $\{case low: goto lowLabel;$ $...$ $case high: goto highLabel;$ $default: goto defaultLabel;\}$
$monitorStmt \rightarrow entermonitor imm; \mid$ $exitmonitor imm;$
$returnStmt \rightarrow return imm; \mid$ $return;$
$throwStmt \rightarrow throw imm;$
$breakpointStmt \rightarrow breakpoint;$
$nopStmt \rightarrow nop;$

$imm \longrightarrow \text{local} \mid \text{constant}$
$conditionExpr \longrightarrow imm_1 \text{ condop } imm_2$ $condop \longrightarrow > \mid < \mid = \mid \neq \mid \leq \mid \geq$
$rvalue \longrightarrow concreteRef \mid imm \mid expr$ $concreteRef \longrightarrow \text{field} \mid$ $\quad \text{local} . \text{field} \mid$ $\quad \text{local} [ imm ]$
$invokeExpr \longrightarrow \text{specialinvoke local.m}(imm_1, \dots, imm_n) \mid$ $\quad \text{interfaceinvoke local.m}(imm_1, \dots, imm_n) \mid$ $\quad \text{virtualinvoke local.m}(imm_1, \dots, imm_n) \mid$ $\quad \text{staticinvoke m}(imm_1, \dots, imm_n)$
$expr \longrightarrow imm_1 \text{ binop } imm_2 \mid$ $\quad (\text{type}) \text{ imm} \mid$ $\quad imm \text{ instanceof type} \mid$ $\quad invokeExpr \mid$ $\quad \text{new refType} \mid$ $\quad \text{newarray (type) } [imm] \mid$ $\quad \text{newmultiaarray (type) } [imm_1] \dots [imm_n] []^* \mid$ $\quad \text{length } imm \mid$ $\quad \text{neg } imm$
$binop \longrightarrow + \mid - \mid > \mid < \mid = \mid \neq \mid \leq \mid \geq \mid * \mid / \mid$ $\quad << \mid >> \mid <<< \mid \% \mid \text{rem} \mid \& \mid \mid \mid$ $\quad \text{cmp} \mid \text{cmpg} \mid \text{cmpl}$



## 4.2 Αφαίρεση θέσεων μνήμης

Κάθε `new` σηματοδοτείται μοναδικά με έναν ακέραιο αριθμό αναπαριστώντας μια θέση μνήμης ενός object.

```
x= new1 A();    //object 1 created here  
y= new2 A();    //object 2 created here
```

Ένα `new` ενδεχομένως να δημιουργήσει περισσότερα από ένα objects. Τα objects που δημιουργούνται από την ίδια εντολή αντιμετωπίζονται σαν ένα

```
while(...){  
    x= new3 A(); //object(s) 3 created here  
    ...  
}
```

Οι θέσεις μνήμης μας, αναπαριστώντας objects, έχουν πεδία. Αναφερόμαστε σε αυτά ως `1.someField`

## 4.3 Points-to Sets

Η πληροφορία “η μεταβλητή `x` αναφέρεται στο object 1” αναπαριστάται με την αντιστοιχία  $x \rightarrow \{1\}$ .

Μια αντισοίχιση του παραπάνω παραδείγματος

```
x= new1 A();    //object 1 created here  
y= new2 A();    //object 2 created here
```

είναι η εξής :

```
x  $\rightarrow$  {1}  
y  $\rightarrow$  {2}
```

## 4.4 May

Μία pointer ανάλυση χαρακτηρίζεται may ή must.  
Σκοπός της παρούσας ανάλυσης είναι οι αντιστοιχίσεις

```
someVariable → {1, 3}  
WRITES(someMethod) → {2.someField, 4.someField}
```

να εκφράζουν ότι η μεταβλητή `someVariable` ενδέχεται να αναφέρεται στο `object 1` ή στο `object 3` και η μέθοδος `someMethod` ενδέχεται να γράφει το πεδίο `someField` στην μνήμη όπου είναι δεσμευμένα τα `objects 2` ή `4`.  
Επομένως η ανάλυσή μας είναι may ανάλυση.

## 4.5 Ασφαλής αφαίρεση προγράμματος

Σκοπός της ανάλυσης είναι οι αντιστοιχίσεις μεταβλητών-θέσεων μνήμης και μεθόδων-παρενεργειών (side effects) να αναπαριστούν κάθε πιθανή εκτέλεση του προγράμματος όντας οι μικρότερες δυνατές.

Οί παρακάτω αντιστοιχίσεις είναι και οι δύο ασφαλείς :

```
x= new1 A();    //object 1 created here  
y= new2 A();    //object 2 created here
```

_____	_____
x → {1}	x → {1, 2}
y → {2}	y → {1, 2}

## 4.6 Intra-procedural

Κάθε μέθοδος της οποίας η κλήση βρίσκεται σε κάποια διαδρομή εκτέλεσης από την αρχή του προγράμματος εξετάζεται μία μοναδική φορά, χωρίς πληροφορία της ροής του προγράμματος

## 4.7 Πρόβλημα ικανοποίησης περιορισμών

Η ανάλυση τελικά ανάγεται σε δύο προβλήματα ικανοποίησης περιορισμών.

Points-to ανάλυση :

Μεταβλητές του προβλήματος είναι τα points-to σύνολα των μεταβλητών του προγράμματος.

Πεδίο ορισμού της κάθε μεταβλητής είναι όλες οι θέσεις μνήμης.

Παρενέργειες :

Μεταβλητές του προβλήματος είναι τα read και write σύνολα κάθε μεθόδου.

Πεδίο ορισμού της κάθε μεταβλητής είναι όλες οι προσβάσεις μνήμης της μορφής `d.someField` όπου `d` είναι μια θέση μνήμης.

Εντολές εκχώρησης και κλήσεων μεθόδων δημιουργούν τους περιορισμούς των προβλημάτων.

Τά προβλήματα μοντελοποιούνται και λύνονται μέσω της βιβλιοθήκης προγραμματισμού με περιορισμούς Choco-solver<sup>4</sup>

## 4.8 Κανόνες Παραγωγής

Οι περιορισμοί παράγονται βάση των εξής κανόνων :

### 4.8.1 Points-to

$$\frac{}{|p = \text{new } A_i()| \mapsto l_i \in p} [new - assignment - statement]$$

$$\frac{}{|p = q| \mapsto p \supseteq q} [copy - statement]$$

$$\frac{}{|i.m(a_1 \dots a_n)| \mapsto m.this \supseteq i \quad p_j \supseteq a_j} [method - invocation - value]$$

όπου  $p_j$  είναι οι παράμετροι της  $m$

$$\frac{}{|q = i.m(a_1 \dots a_n)| \mapsto q \supseteq m} [method - assignment - statement]$$

$$\frac{}{|return p| \mapsto m \supseteq p} [return - statement]$$

όπου  $m$  είναι η μέθοδος στην οποία το σώμα βρίσκεται η εντολή

Οι μεταβλητές που έχουν τύπο πίνακα ενοποιούνται

$$\frac{}{|p = q| \mapsto p \supseteq q \quad q \supseteq p} [array - copy - statement]$$

οπού οι  $p$  και  $q$  είναι μεταβλητές τύπου πίνακα

Οι παραπάνω περιορισμοί έχουν την αναμενόμενη σημασιολογία

$$\frac{p \supseteq q \quad l_x \in q}{l_x \in p} [superset]$$

Οι εκχωρίσεις μεταξύ πεδίων παράγουν τους εξής περιορισμούς

$$\frac{}{|p = q.f| \mapsto p \supseteq q.f} [field-read-assignment-statement]$$

$$\frac{}{|p.f = q| \mapsto p.f \supseteq q} [field-assign-assignment-statement]$$

Με την εξής σημασιολογία

$$\frac{p \supseteq q.f \quad l_q \in q \quad l_f \in l_q.f}{l_f \in p} [field-read]$$

$$\frac{p.f \supseteq q \quad l_p \in p \quad l_q \in q}{l_q \in l_p.f} [field-assign]$$

## 4.8.2 Παρενέργειες

$$\frac{}{|p=q.f| \mapsto q.f :: \text{Read of } m} [side - effect - read - statement]$$

$$\frac{}{|p.f=q| \mapsto p.f :: \text{Write of } m} [side - effect - write - statement]$$

$$\frac{}{|m_2(\dots)| \mapsto \text{READS}(m) \supseteq \text{READS}(m_2), \text{WRITES}(m) \supseteq \text{WRITES}(m_2)} [side - effect - invocation - value]$$

όπου  $m$  η μέθοδος στις οποίας το σώμα βρίσκονται η εντολές και η  $m_2$  δεν είναι μέθοδος `run()`

## 4.9 DaCapo Benchmarks

<κειμενο>

## 5 Επίλογος

<κειμενο>

# ΑΝΑΦΟΡΕΣ

- [1] Java Language Specification, Java SE 7 Edition  
<https://docs.oracle.com/javase/specs/jls/se7/html/jls-17.html#jls-17.4.5>
- [2] SootUp  
<https://soot-oss.github.io/SootUp/latest/>
- [3] Soot : a java bytecode optimization framework, Raja Vallée-Rai master thesis
- [4] Choco-solver  
<https://choco-solver.org/>